

Konzeptpapier für eine Plattform zur Messung globaler Medienaufmerksamkeit

Artikel verlinken statt Inhalte replizieren

Konzeptstand: August 2026

Ziel: Beobachtung, Verknüpfung und Visualisierung der globalen Verbreitung von Nachrichtenereignissen

1. Leitidee

Die geplante Plattform soll nicht primär Nachrichten aggregieren oder Artikeltexte nachpublizieren. Sie soll sichtbar machen, wie sich mediale Aufmerksamkeit durch die globale Newslandschaft bewegt: Wer berichtet über ein Ereignis, wer berichtet nicht, wann überschreitet eine Meldung Länder- oder Sprachgrenzen, welche Medien und Agenturen fungieren als Gateways, und wann wächst ein einzelnes Ereignis zu einem Ereignis-Cluster oder dauerhaften Thema an?

Das Produkt ist damit weniger eine Nachrichtensammlung als eine kartografische und analytische Ebene über der Nachrichtenwelt. Die Plattform beobachtet Medien, speichert schlanke Metadaten und verlinkt konsequent auf die Originalartikel.

Kernprinzip: Originalquelle bleibt beim Medium. Die Plattform speichert nur die für Analyse und Verknüpfung nötigen Metadaten und führt Nutzer:innen per Link zum Artikel zurück.

2. Was die Plattform beobachtet

Die Plattform beobachtet nicht die Welt direkt, sondern deren mediale Abbildung. Ein Ereignis kann stark, schwach oder gar nicht in den beobachteten Medien erscheinen. Diese Differenz ist selbst ein Teil des Untersuchungsgegenstands.

Die wichtigste methodische Regel lautet deshalb: Beobachtung und Interpretation trennen. Messbar ist beispielsweise, dass 4 von 38 beobachteten Schweizer Outlets innerhalb von 48 Stunden über ein Ereignis berichteten. Eine Aussage darüber, warum dies so war, ist eine separate Interpretation.

3. Kernobjekte des Datenmodells

Die Architektur folgt einer klaren Hierarchie: Medien-Eigentümer → Outlet → Artikel → Ereignis → Ereignis-Cluster → Thema → Meta-Thema. Parallel dazu existieren sprachneutrale Entitäten wie Orte, Länder, Personen, Organisationen, Sprachen und Nachrichtenagenturen.

Der Artikel ist das kleinste beobachtete Medienobjekt. Das Ereignis ist das zentrale analytische Objekt. Mehrere Artikel verschiedener Medien können demselben Ereignis zugeordnet werden. Mehrere kausal oder narrativ verbundene Ereignisse können einen Ereignis-Cluster bilden. Ein Thema verbindet Ereignisse semantisch, auch wenn sie nicht unmittelbar kausal zusammenhängen.

4. Datenobjekte und minimale Tiefe

Objekt	Beispiel	Minimal speichern	Nicht zwingend speichern
Outlet	NZZ	Name, Domain, Land, Sprache, Typ, Eigentümer, Einstiegspunkte	Vollständiges Redaktionsprofil
Artikel	NZZ-Artikel zum Waldbrand	Titel, URL, Zeit, Sprache, Ressort, Kurzbeschreibung aus Feed/Metadaten	Volltext oder dauerhaftes Artikelarchiv
Ereignis	Waldbrand bei Málaga	Was, wann, wo, wer, Event-ID	Jede Detailinformation des Ereignisses
Event-Cluster	Waldbrände Andalusien	verbundene Event-IDs,	vollständige Chronologie

	August 2026	Zeitraum, Hauptort	jeder Quelle
Thema	Extreme Hitze in Europa 2026	Topic-ID, Label, verbundene Cluster	Essayartige Inhaltszusammenfassung

5. Einstiegspunkte in die Medienquellen

Die Plattform sollte pro Outlet mehrere mögliche Einstiegspunkte kennen. Diese sind Sensoren für neue Artikel - nicht das Ziel einer tiefen Datenspiegelung. Je nach Medium kann ein anderer Einstiegspunkt die beste Qualität liefern.

Einstiegspunkt	Nutzen	Empfohlene Datentiefe	Priorität
RSS / Atom Feed	Bevorzugter Einstiegspunkt, wenn verfügbar. Liefert neue Artikel strukturiert mit Titel, Link, Zeit und oft Kurzbeschreibung oder Kategorie. Sehr ressourcenschonend und gut für kontinuierliches Monitoring.	Nur Feed-Metadaten übernehmen; Artikeltext nicht zwingend abrufen.	hoch
News-Sitemap	Sehr geeignet für Medien ohne guten RSS-Feed. News-Sitemaps enthalten meist aktuelle Artikel-URLs und Publikationszeiten, teils Titel und Sprache.	URL + Zeit + ggf. Titel übernehmen; danach nur Artikel-Metadaten ergänzen.	hoch
Homepage / Ressortseiten	Fallback und zusätzlicher Prominenz-Sensor. Hilfreich, um zu erkennen, welche Meldung auf der Startseite oder in einem Ressort hervorgehoben wird.	Links, Position, Zeitpunkt und ggf. Teaser erfassen; keine dauerhafte Vorkopie der Seite.	mittel
Publisher API	Falls vorhanden, oft der sauberste strukturierte Zugriff. Kann IDs, Kategorien, Autor:innen und weitere Metadaten liefern.	Nur benötigte Metadaten abrufen und API-Nutzungsbedingungen beachten.	hoch
NewsML-G2 / Agenturfeed	Besonders wertvoll bei professionellen Nachrichtenagenturen. Kann Ereignisse, Topics, IDs und Provenienz bereits strukturiert liefern.	Strukturierte Metadaten verwenden; Content-Rechte strikt beachten.	hoch
Google News / Aggregator-Feed	Praktischer Fallback für Medien ohne öffentlich auffindbaren Feed. Hilft	Nur als Discovery-Kanal behandeln; Original-URL und Originalmedium	mittel

	beim Entdecken neuer Artikel einer Domain.	bleiben maßgeblich.	
Social / Push / Newsletter	Optional als Signal für Prominenz oder Breaking News. Nicht als primäre Artikelquelle.	Zeitpunkt und verlinkten Originalartikel erfassen.	niedrig bis mittel

6. Empfohlener Ingestion-Flow

1. Quelle beobachten

Feed, Sitemap, Homepage oder API regelmäßig prüfen.

2. neuen Artikel erkennen

Canonical URL oder Publisher-ID als primäre Identität verwenden; Dubletten vermeiden.

3. Minimalmetadaten speichern

Outlet-ID, URL, Titel, Publikationszeit, Sprache, Kategorie/Ressort, Feed-/Quellentyp.

4. Artikel nur leicht anreichern

Falls nötig HTML-Metadaten, Schema.org, OpenGraph oder kurze Teaserinformationen lesen. Kein Volltextarchiv als Standard.

5. Entitäten erkennen

Orte, Länder, Personen, Organisationen und Nachrichtenagenturen normalisieren.

6. Event Matching

Prüfen, ob der Artikel ein bestehendes Ereignis beschreibt oder ein neues Event erzeugt.

7. Aufmerksamkeit aktualisieren

Länder-, Sprach-, Eigentums- und Zeitverteilung für das Ereignis neu berechnen.

8. Nutzer:innen zum Original führen

Jede Artikelanzeige verlinkt auf die Originalquelle.

7. Artikel → Ereignis → Cluster → Thema

7.1 Ereignis

Ein Ereignis ist möglichst konkret, räumlich und zeitlich begrenzt und beantwortet WHAT, WHEN, WHERE und WHO. Beispiel: „Am 19. August breitet sich ein Waldbrand bei Málaga aus und mehrere Gemeinden werden evakuiert.“

7.2 Event Matching

Mehrsprachige Artikel werden anhand von semantischer Ähnlichkeit, gemeinsamen Entitäten, Ort, Zeit und Ereignistyp demselben Event zugeordnet. Der Event-Match bleibt probabilistisch und erhält einen Confidence-Wert.

7.3 Ereignis-Cluster

Ein Cluster verbindet mehrere unterschiedliche, aber kausal oder narrativ eng zusammenhängende Ereignisse, etwa Feuerbeginn, Evakuierung, Notstand und Eindämmung eines Waldbrands. Entscheidend sind zeitliche Kontinuität, geografische Nähe, gemeinsame Akteure und Cross-Event-Referenzen.

7.4 Thema

Ein Thema ist breiter als ein Cluster und kann unabhängige Ereignisse verbinden. „Migration im Mittelmeer“ oder „Nahostkonflikt“ sind Themen; einzelne Angriffe, Verhandlungen oder Gesetzesentscheide sind Ereignisse bzw. Cluster. Für stabile Basisthemen sollte eine kontrollierte Taxonomie wie IPTC Media Topics verwendet werden; aktuelle, dynamische Themen können zusätzlich algorithmisch entstehen.

8. Mehrsprachigkeit

Originalsprache und Originaltitel bleiben erhalten. Events, Orte, Personen und Topics werden dagegen über sprachneutrale IDs normalisiert. So können „Spain“, „España“, „Spanien“ und „Espagne“ auf dasselbe Länderobjekt zeigen. Multilinguale semantische Repräsentationen ermöglichen Event Matching ohne zwingende Vorübersetzung aller Artikel.

Übersetzungen dienen primär der Benutzeroberfläche oder Analyse. Sie ersetzen nicht den Originaltitel und sollten als abgeleitete Daten gekennzeichnet werden. Gerade für spätere Framing-Analysen ist die originale Wortwahl zentral.

9. Wann wird ein Ereignis international?

Internationalität sollte nicht binär sein. Sie ist ein zeitlicher Prozess und setzt sich aus mehreren Dimensionen zusammen. Ein Ereignis mit 30 Artikeln aus fünf Weltregionen und neun Sprachräumen kann internationaler sein als eines mit 100 Artikeln aus drei Nachbarländern.

Dimension	Frage
Geographic Spread	Wie viele Länder berichten?
World Region Spread	Wie viele Weltregionen werden erreicht?
Linguistic Spread	Wie viele Sprachräume greifen das Ereignis auf?
Ownership Spread	Wie viele unabhängige Medien-Eigentümer berichten?
Source Diversity	Wie viele erkennbare ursprüngliche Informationsquellen/Agenturen liegen zugrunde?
Diffusion Velocity	Wie schnell überschreitet die Meldung nationale, sprachliche und regionale Grenzen?

Für die Oberfläche können verständliche Stufen genutzt werden: LOCAL → NATIONAL → CROSS-BORDER → REGIONAL → INTERNATIONAL → GLOBAL. Darunter bleiben die Rohwerte transparent verfügbar.

10. Wer berichtet - und wer nicht?

Die reine Anzahl berichtender Medien ist nur die erste Ebene. Wichtig ist die Relation zur beobachteten Medienlandschaft. Die Plattform sollte pro Ereignis zeigen, welche Outlets, Länder, Sprachräume und Eigentümer berichten sowie welche erwartbaren Outlets fehlen.

„Nicht berichtet“ ist erst dann analytisch aussagekräftig, wenn eine Coverage Expectation existiert. Diese kann aus dem historischen Verhalten eines Mediums gelernt werden: Berichtet das Outlet normalerweise

über vergleichbare Ereignisse dieser Region und dieses Themas? Eine Abwesenheit bei 90 % erwarteter Berichterstattungswahrscheinlichkeit ist interessanter als bei 3 %.

11. Aufmerksamkeit statt bloßer Artikelzahl

Internationality und Attention sind getrennte Größen. Attention misst Intensität: Artikelzahl, Zahl der Outlets, Wiederholungen, Follow-ups, Dauer und später optional Prominenz auf Homepages. Daraus lassen sich Attention Peak, Attention Half-Life und Attention Anomaly ableiten.

Die Attention Anomaly vergleicht beobachtete Aufmerksamkeit mit ähnlichen Ereignissen. So wird sichtbar, welche Ereignisse im Verhältnis zu Typ, Region, Größe oder Betroffenheit über- oder unterdurchschnittlich viel mediale Aufmerksamkeit erhalten.

12. Minimaler Artikeldatensatz

Da die Plattform keine Volltextdatenbank sein soll, reicht für die erste Ausbaustufe ein schlanker Artikeldatensatz:

- article_id
- outlet_id
- canonical_url
- headline_original
- published_at
- updated_at (optional)
- language
- section/category (optional)
- short_description/teaser (wenn aus Feed verfügbar)
- discovery_source (RSS, sitemap, homepage, API ...)
- primary_event_location
- entities[]
- event_id
- event_match_confidence
- source_agency (wenn erkennbar)
- first_seen_at

Der Artikeltext selbst kann bei Bedarf temporär für NLP analysiert werden, muss aber nicht als dauerhaft gespeicherter Plattforminhalt vorgesehen werden. Für die Benutzeroberfläche genügt der Link zum Originalartikel.

13. Provenienz und Confidence

Jedes algorithmisch erzeugte Feld sollte seine Herkunft kennen: Wert, Methode, Quelle, Confidence und Zeitstempel. Das gilt besonders für Event Matching, Orte, Source Attribution und Topic-Zuordnung. Menschliche Korrekturen sollten nachvollziehbar protokolliert werden.

14. Zentrale Plattformansichten

Ansicht	Kernfrage
Event	Welche Medien berichten? Welche nicht? Wie verbreitet sich das Ereignis über Länder, Sprachräume und Eigentümer?
Outlet	Worüber berichtet dieses Medium typischerweise?

	Welche Regionen und Themen dominieren? Welche Events fehlen überraschend?
Land	Worüber berichten Medien eines Landes in der Welt - und wie berichtet die Welt über dieses Land?
Topic	Welche aktiven Ereignisse und Cluster gehören zu einem Thema? Wie wächst oder schrumpft die Aufmerksamkeit?
Diffusion	Zeitliche Karte der Verbreitung: lokales Medium → Agentur → andere Länder/Sprachen → global.

15. Empfohlene Entwicklungsphasen

Phase 1 - Quellenmodell: Outlets, Eigentümer, Länder, Sprachen und Einstiegspunkte definieren.

Phase 2 - Artikel-Ingestion: RSS/Atom, Sitemaps und ausgewählte Homepages anbinden; nur Metadaten und Links erfassen.

Phase 3 - Event Engine: Article-to-Event-Matching, Event IDs, Merge/Split und Location/Entity-Normalisierung.

Phase 4 - International Diffusion: Länder-, Sprach-, Eigentums- und Zeitverbreitung messen.

Phase 5 - Event Cluster & Topics: verbundene Ereignisse und dynamische Themen erkennen.

Phase 6 - Attention Intelligence: Internationality, Attention, Diversity, Coverage Expectation und Anomaly.

Phase 7 - qualitative Analyse: Framing, Wortwahl und Quellenstruktur erst später ergänzen.

16. Zielarchitektur in einem Satz

**OUTLET → RSS / SITEMAP / HOMEPAGE / API → ARTIKEL-METADATEN + LINK →
EVENT → EVENT-CLUSTER → TOPIC → ATTENTION & DIFFUSION**

Das Leitbild der Plattform lautet: Nicht die Nachrichten selbst sind das Produkt, sondern die Bewegung von Aufmerksamkeit durch die globale Medienlandschaft.

17. Relevante Standards und Referenzsysteme

IPTC Media Topics: kontrollierte, sprachneutrale Nachrichtentaxonomie

NewsML-G2 / EventsML-G2: Strukturierung von Nachrichten, Konzepten, Ereignissen und Beziehungen

Schema.org NewsArticle: Web-Metadaten wie headline, datePublished, contentLocation und dateline

RSS / Atom: strukturierte Discovery neuer Artikel

News Sitemap: URL- und Zeit-basierte Discovery aktueller News-Artikel

Wikidata / GeoNames: sprachneutrale IDs für Orte, Organisationen und weitere Entitäten